

Projekt Optymalizacja nieliniowa

Cz 2 Optymalizacja wielowymiarowa

Krawiec Piotr
Inżynieria i analiza danych, 3 Rok


01/12/2021

Wstęp

Celem tej pracy jest omówienie metody gradientów sprzężonych Polaka-Ribiere'a, jej implementacja w R oraz rozwiązanie z jej pomocą zadania optymalizacyjnego.

Problem



Istnieje wiele algorytmów optymalizacji co zrodziło potrzebę porównania ich, wyłonienia, który jest najlepszy. Do tego celu powstały funkcje testujące algorytmy optymalizacji ¹ . Ich pierwszy zbiór został stworzony jako pakiet w programie Matlab przez Rody Oldenhuis i zawierał 50 funkcji testowych.



Rysunek 1: Funkcja Rastrigina

¹https://en.wikipedia.org/wiki/Test_functions_for_optimization

Inne przykłady: Funkcja Rosenbrock'a oraz Goldstein'a-Price'a




Zadanie

Zadaniem będzie znalezienie minimum funkcji Goldstein'a-Price'a o następującym równaniu:


$$f(x, y) = \left[1 + (x + y + 1)^2 (19 - 14x + 3x^2 - 14y + 6xy + 3y^2) \right] \\ \left[30 + (2x - 3y)^2 (18 - 32x + 12x^2 + 48y - 36xy + 27y^2) \right]$$

```
f <- function(x, y) {
  (1 + (x + y + 1)^2 *
    (19 - 14 + 3*x^2 - 14*y + 6*x*y + 3*y^2)) *
  (30 + (2*x - 3*y)^2*(18 - 32*x + 12*x^2
    + 48*y-36*x*y + 27*y^2))
}
```


Wykres funkcji




Wykres funkcji - zbliżenie na miejsce zerowe




Wykres - 3D




Wykres - 3D




Wykres - 3D




Wykres - 3D




Wykres - 3D




Wykres - 3D



Wykres - 3D



Wykres - 3D



Metoda gradientów sprzężonych Polaka-Ribiere'a

Jest to iteracyjna metoda optymalizacji bez ograniczeń. Odróżnia się od innych metod gradientowych tym, iż do obliczenia kolejnego kierunku poszukiwań korzysta z gradientu z poprzedniej iteracji (stąd sprzężenie w nazwie). Ogólna zasada jest podobna do metod gradientowych, w kroku pierwszym poszukujemy gradientu, który wskaże nam kierunek poszukiwania najmniejszego punktu:

$$d(0) = -\nabla f(x^{(0)})$$

Następnie w każdym z kolejnych $d^{(i+1)}$, uwzględniać będziemy β , które zawiera gradient.

$$d^{(i+1)} = -\nabla f(x^{(i+1)}) + \beta^{(i+1)} d^{(i)}$$

Gdzie:

$$\beta^{i+1} = \frac{\nabla f(x^{(i+1)})^T (\nabla f(x^{(i+1)}) - \nabla f(x^{(i)}))}{\nabla f(x^{(i)})^T \nabla f(x^{(i)})}$$

Metoda gradientów sprzężonych Polaka-Ribiere'a

I ostatecznie, kolejne przybliżenie szukanego minimum można znaleźć:

$$x^{(i+1)} = x^{(i)} + h^{(i)} * d^{(i)}$$

Przy czym, h - długość kroku można wyznaczyć na kilka sposobów. Najbardziej optymalnym jest aktualizacja tej wartości w każdej iteracji. Można to robić poszukując minimum funkcji wzdłuż kierunku poszukiwań d .

$$g(\alpha) = f(x^{(i)} + \alpha d^{(i)})$$

Wtedy, dla dla znalezionej g_{min} i α_{min} :

$$h^{(i)} = \alpha_{min}$$

Minimum funkcji g poszukuje się z pomocą metod optymalizacji jednowymiarowej.

Metody optymalizacji jednowymiarowej - mały (wielki) problem

I tutaj pojawia się mały problem, metody optymalizacji jednowymiarowej wymagają podania przedziału, w którym może znajdować się minimum. Może zdarzyć się tak, że dla dużych d , źle dobrany przedział poszukiwań $[a, b]$ sprawi, że krok $h^{(i)}$ będzie bardzo duży i nie trafimy w minimum. Co może się zdarzyć dla bardzo “płaskich” funkcji.

Dokładnie na taki problem natrafiłem podczas pracy. Funkcja w okolicach minimum posiadała bardzo duży gradient i w następnej iteracji x znacząco oddalał się od minimum.

Algorytm był zbieżny wyłącznie dla minimum, oddalenie się o 0.01 powodowało rozbieżność.

Próba rozwiązania problemu

Pierwszą rzeczą, której spróbowała najoczywistsza rzecz tj. ograniczenie gradientu. W przypadku gdy stawał się zbyt duży, dzieliłem go przez jego długość. Sprawdziło się to wyłącznie w początkowych iteracjach, ponieważ gdyż w przypadku gdy krok $h^{(i)}$ otrzymany przez metodę optymalizacji jednowymiarowej był zbyt duży, nadal oddalałem się od minimum.

Rozwiązanie problemu

Zmiana gradientu okazała się nietrafionym pomysłem, ponieważ przy okazji zmieniał się parametr β . Zamiast tego zmieniłem przedział poszukiwań optymalnego kroku, ponieważ to on ostatecznie był dodawany do x . Ideальnym przedziałem okazał się

$$[a, b] = \left[\max \left\{ \frac{-1}{|d|}, -|d| \right\}, \min \left\{ \frac{1}{|d|}, |d| \right\} \right]$$

W przypadku bardzo dużych d , przedział poszukiwań był bardzo zawężony, co sprawiało, że krok także się zmniejszał.

Próbowałem także zmienić algorytm optymalizacji jednowymiarowej i dla podanej funkcji jedynym, który zadziałał był algorytm golden. Z algorytmem Fibonacciego już w drugiej iteracji (dla tych samych parametrów) x stawał się duży, a algorytm nie był zbieżny.

Algorytm golden

```
golden <- function(f, lower, upper, tol) {  
  ratio <- 2 / (3 + sqrt(5))  
  x1 <- (1 - ratio) * lower + ratio * upper  
  f.x1 <- f(x1)  
  while (abs(upper - lower) > 2 * tol) {  
    x2 <- (1 - ratio) * x1 + ratio * upper  
    f.x2 <- f(x2)  
    if (f.x1 < f.x2) {  
      upper <- lower  
      lower <- x2  
    } else {  
      lower <- x1  
      x1 <- x2  
      f.x1 <- f.x2  
    }  
  }  
}
```

Metoda gradientów sprzężonych Polaka-Ribiere'a - kod w R

```

library(numDeriv)
polak.ribiere <- function(f, x, tol) {
  beta <- 1; i <- 1;
  d <- -grad(f, x,)
  repeat {
    g <- function(a) {f(x + a * d)}
    d.magnitude <- sqrt(sum(d^2));
    grad.x <- grad(f, x)
    step <- golden(g,
                  max(c(-1/d.magnitude,-d.magnitude)),
                  min(c(1/d.magnitude,d.magnitude)), tol)
    new.x <- x + step * d
    grad.new.x <- grad(f, new.x)
    cat("(",i,")", "x=", x,"step=",step, "new.x=", new.x, "grad.x=",
        grad.x, "\n(",i,")", "grad.new.x=", grad.new.x, "d=", d, "\n");
    if (dist(rbind(new.x,x)) < tol) {
      return(new.x)
    }
    beta <- t(grad.new.x) %*%
              (grad.new.x - grad.x) /
              (t(grad.x) %*% grad.x)
    d <- -grad(f,new.x) + as.vector(beta) * d;
    x <- new.x; i <- i + 1;
  }
}

```

Rozwiązanie zadania

```
fn <- function(x) f(x[1], x[2]);
m <- polak.ribiere(fn, c(-0.5, -0.5), 1e-3)
```

```
## ( 1 ) x= -0.5 -0.5 step= 0.004422321 new.x= -0.5663348 -0.4004978 grad.x= 15 -22.5
## ( 1 ) grad.new.x= 31.14325 19.24268 d= -15 22.5
## ( 2 ) x= -0.5663348 -0.4004978 step= 0.00111821 new.x= -0.631116 -0.3770805 grad.x= 31.14325 19.24268
## ( 2 ) grad.new.x= -17.78508 10.04248 d= -57.93287 20.94176
## ( 3 ) x= -0.631116 -0.3770805 step= -0.001646764 new.x= -0.6050355 -0.3805576 grad.x= -17.78508 10.04248
## ( 3 ) grad.new.x= 6.04749 19.4507 d= -15.83741 2.111483
## ( 4 ) x= -0.6050355 -0.3805576 step= 0.0003170421 new.x= -0.6108902 -0.3861993 grad.x= 6.04749 19.4507
## ( 4 ) grad.new.x= -2.596436 9.747444 d= -18.46667 -17.79495
## ( 5 ) x= -0.6108902 -0.3861993 step= 0.09671282 new.x= -0.04925789 -1.029674 grad.x= -2.596436 9.747444
## ( 5 ) grad.new.x= -12.53166 -8.918604 d= 5.807217 -6.653455
## ( 6 ) x= -0.04925789 -1.029674 step= 0.0002636252 new.x= -0.04157633 -1.032338 grad.x= -12.53166 -8.918604
## ( 6 ) grad.new.x= -8.018823 -13.92914 d= 29.1382 -10.10787
## ( 7 ) x= -0.04157633 -1.032338 step= 0.003018632 new.x= -0.004876797 -0.9946255 grad.x= -8.018823 -13.92914
## ( 7 ) grad.new.x= -3.580418 5.535574 d= 12.15767 12.4934
## ( 8 ) x= -0.004876797 -0.9946255 step= 0.001019029 new.x= 0.003177166 -0.9957393 grad.x= -3.580418 5.535574
## ( 8 ) grad.new.x= 0.05488171 2.356969 d= 7.903569 -1.093039
## ( 9 ) x= 0.003177166 -0.9957393 step= 0.001951316 new.x= 0.0004823992 -0.9999806 grad.x= 0.05488171 2.356969
## ( 9 ) grad.new.x= 0.1968787 -0.1297763 d= -1.380999 -2.173571
## ( 10 ) x= 0.0004823992 -0.9999806 step= 0.001764625 new.x= -1.876585e-05 -0.9999936 grad.x= 0.1968787 -0.1297763
## ( 10 ) grad.new.x= -0.009753898 0.01062207 d= -0.2840066 -0.007355346
```

Rozwiązanie zadania - sprawdzenie

Wynik ten pokrywa się z rozwiązaniem podawanym przez WolframAlpha

Input interpretation

minimize

$$(1 + (x + y + 1)^2 (19 - 14 + 3x^2 - 14y + 6xy + 3y^2)) \\ (30 + (2x - 3y)^2 (18 - 32x + 12x^2 + 48y - 36xy + 27y^2))$$

Global minima

(no global minima found)

Local minima


Approximate form

$$\min\left((1 + (x + y + 1)^2 (19 - 14 + 3x^2 - 14y + 6xy + 3y^2)) \right. \\ \left. (30 + (2x - 3y)^2 (18 - 32x + 12x^2 + 48y - 36xy + 27y^2))\right) = \\ 30 \text{ at } (x, y) = \left(-\frac{3}{5}, -\frac{2}{5}\right)$$


$$\min\left((1 + (x + y + 1)^2 (19 - 14 + 3x^2 - 14y + 6xy + 3y^2)) \right. \\ \left. (30 + (2x - 3y)^2 (18 - 32x + 12x^2 + 48y - 36xy + 27y^2))\right) = \\ 3 \text{ at } (x, y) = (0, -1)$$

Rysunek 2: Wynik podany przez Wolframa


Rozwiązanie - wizualizacja




Rozwiązanie - wizualizacja




Rozwiązanie - wizualizacja




Rozwiązanie - wizualizacja




Rozwiązanie - wizualizacja




Rozwiązanie - wizualizacja




Rozwiązanie - wizualizacja



Rozwiązanie - wizualizacja



Rozwiązanie - wizualizacja



Rozwiązanie - wizualizacja

